Del ML clásico al Deep Learning: predicción del abandono de clientes a partir de su secuencia semanal de compras con GRU, LSTM y Transformer

ACA N° 2 · Aprendizaje Automático · Especialización en Inteligencia Artificial · CUN – Escuela de Ingeniería · Docente: Hamilton Rivera Flor
Integrantes: Juan Guillermo Angel Jaramillo · Luis Bernardo Correa Restrepo · María Alejandra Manga Betancourt

App: https://aca2-abandono-clientes-dl-juan-angel-tuqs2bahdtmtheu3bhrzfa.streamlit.app/
Video: *(enlace del video – por publicar)*
Código: https://github.com/leiderpq5521-creator/ACA2-Abandono-Clientes-DL-Juan-Angel

Objetivo general

Entrenar redes neuronales secuenciales (GRU, LSTM y Transformer temporal) que lean la **historia semanal de compras** de cada cliente para anticipar su abandono, compararlas con el Random Forest del ACA 1 en los mismos clientes y desplegar la mejor en una app Streamlit explicable.

Situación problema

¿Cómo aprovechar redes neuronales (CNN, RNN, Transformers) para extraer patrones complejos en datos de ventas y llevarlos a una interfaz interactiva?

En el ACA 1 el modelo veía una **foto** del cliente (recencia, frecuencia, gasto). Ahora la red ve la **película**: 40 semanas de compras, con su orden y su ritmo.

Dataset: UCI Online Retail (Chen, 2015)

- 541.909 líneas de factura (dic-2010 → dic-2011) de un minorista en línea del Reino Unido; 391.148 ventas limpias.
- 3.314 clientes con compras antes del corte del 1-sep-2011; **abandono** = no vuelve a comprar después (41,2 %).
- Partición idéntica al ACA 1: train 2253 · val 398 · prueba 663.

Ruta metodológica

1 · Exploración y SQL
Transacciones en **SQLite**; calidad, EDA y limpieza con consultas y **vistas SQL** (nulos, duplicados, cancelaciones, precios ≤ 0).

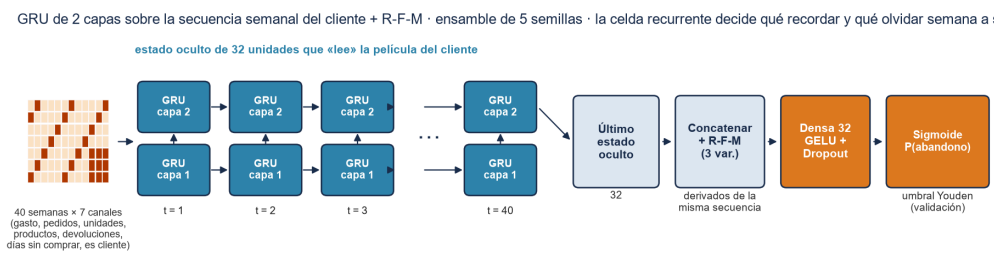
2 · Pipeline
Secuencias de 40 semanas × 7 canales; escalado sólo con train; partición por cliente sin fuga; **aumento** (escalado, jitter, recorte de ventana); pos_weight.

3 · Modelado
RF del ACA 1 (base) · **GRU** · **LSTM** · **Transformer** temporal; 5 semillas; AdamW y early stopping por AUC de validación.

4 · Evaluación
Curvas por época, ROC/PR, matriz de confusión, IC 95 % bootstrap, ΔAUC pareado, permutación, oclusión y atención.

5 · Despliegue
App Streamlit: cliente, secuencia manual, lotes CSV, historial y consultas SQL, desempeño y selector de modelos.

Arquitectura elegida para la app (mayor ROC-AUC en validación): GRU (red recurrente con compuertas) + R-F-M



Lee las 40 semanas en orden; sus compuertas de actualización y reinicio deciden qué recordar del pasado. El último estado oculto (32) se concatena con R-F-M y pasa a una capa densa con salida sigmoide. 11.457 parámetros por red · ensamble de 5 semillas · AdamW. early stopping por AUC de validación.

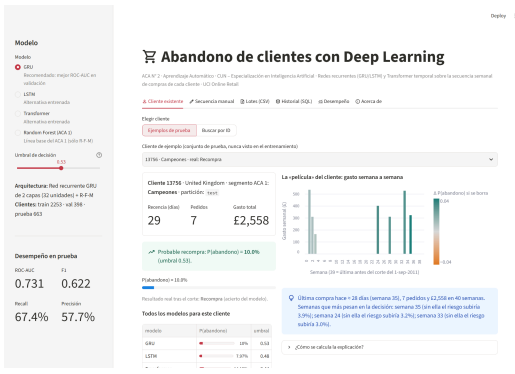
Resultados en prueba (n = 663, los mismos clientes del ACA 1)

0,731	0,720	67,4 %	0,622
ROC-AUC GRU	ROC-AUC RF ACA 1	Recall abandono	F1

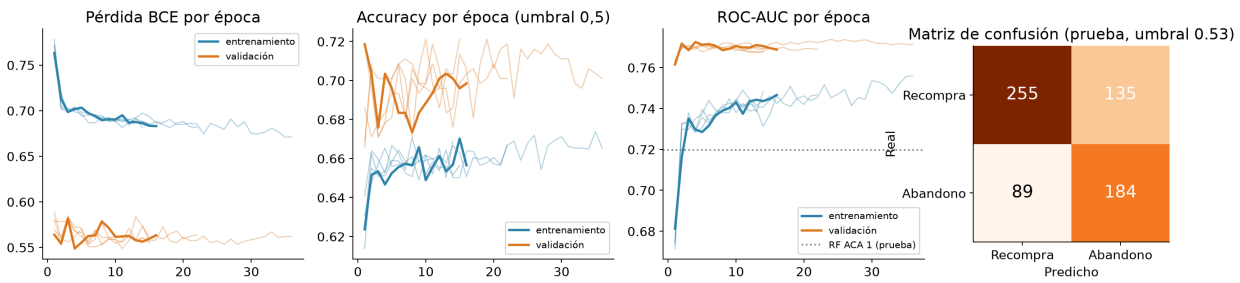
Modelo	Parám.	AUC val	Accuracy	ROC-AUC	F1	Recall	Precisión	ΔAUC vs RF [IC 95 %]
Random Forest (ACA 1)	—	—	0,642	0,720	0,654	0,821	0,544	—
GRU	**11,5 k**	**0,774**	**0,662**	**0,731**	**0,622**	**0,674**	**0,577**	**+0,011 [−0,000; +0,022]**
LSTM	14,9 k	0,771	0,658	0,730	0,640	0,740	0,564	+0,010 [−0,002; +0,021]
Transformer	19,9 k	0,769	0,661	0,731	0,648	0,758	0,566	+0,011 [−0,001; +0,024]

IC 95 % (bootstrap, 2.000 remuestreos pareados) de GRU: ROC-AUC 0,693–0,766 · F1 0,575–0,666 · recall 0,618–0,728. ΔAUC frente al RF: +0,011 (p = 0,052). Umbrales elegidos en validación (regla de Youden del ACA 1). **Al mismo punto de operación** (recall ≥ 0,80 fijado en validación): GRU 218 abandonos detectados con 170 falsas alarmas; RF 224 con 188.

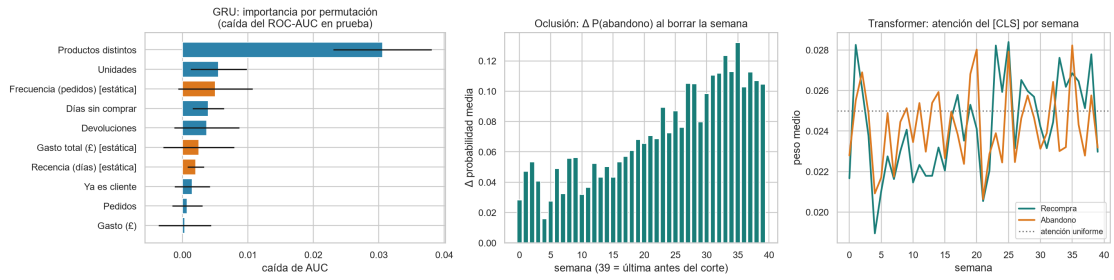
Vista previa de la app Streamlit



GRU: curvas de pérdida, accuracy y ROC-AUC por época (5 semillas) y matriz de confusión



Interpretabilidad



Lo más influyente para GRU es **Productos distintos** (caída de AUC 0,031), luego Unidades y Frecuencia (pedidos) [estática]. Borrar una compra de las 8 últimas semanas cambia P(abandono) en +0,113 frente a +0,041 en el primer trimestre. El [CLS] del Transformer dedica 20,3 % de su atención a esas 8 semanas (20 % si fuera uniforme).

Conclusiones

- Con la misma etiqueta y los mismos 663 clientes de prueba del ACA 1, la red elegida por validación (GRU, ensamble de 5 semillas) obtiene ROC-AUC 0,731 frente a 0,720 del Random Forest R-F-M (ΔAUC pareado +0,011; IC 95 % −0,000 a +0,022).
- Las tres redes superan al RF por un margen similar, pero el intervalo de la diferencia toca el cero: la mejora es consistente aunque pequeña y no concluyente con 663 clientes. Con secuencias tan dispersas, buena parte de la señal ya está en R-F-M.
- Al mismo punto de operación (recall ≥ 0,80, umbral fijado en validación), GRU detecta 218 abandonos con 170 falsas alarmas frente a 224 y 188 del RF (precisión 0,562 vs 0,544).
- La secuencia aporta sobre todo en el segmento «Recientes» (AUC 0,583 vs 0,514) y en clientes con varios pedidos; en «Dormidos» ningún modelo supera AUC 0,552.
- Interpretabilidad: lo más influyente es productos distintos y borrar una compra de las últimas 8 semanas sube el riesgo +0,113 frente a +0,041 en el primer trimestre: la red pondera lo reciente. La atención del Transformer resultó casi uniforme, por lo que la oclusión es la explicación usada en la app.
- El límite está en los clientes de un solo pedido (42 % de la base): su error es 41 % frente a 13 % en clientes con 4+ pedidos.

Referencias (APA 7)

Chen, D. (2015). *Online Retail* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5BW33

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. En *Proceedings of EMNLP 2014* (pp. 1724–1734). https://doi.org/10.3115/v1/D14-1179

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Iwana, B. K., & Uchida, S. (2021). An empirical survey of data augmentation for time series classification with neural networks. *PLOS ONE, 16*(7), e0254841. https://doi.org/10.1371/journal.pone.0254841

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems 30* (pp. 5998–6008). https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

Enlaces del proyecto

App Streamlit: https://aca2-abandono-clientes-dl-juan-angel-tuqs2bahdtmtheu3bhrzfa.streamlit.app/
Video de sustentación: *(enlace del video – por publicar)*
Código (GitHub): https://github.com/leiderpq5521-creator/ACA2-Abandono-Clientes-DL-Juan-Angel